UNIVERSIDAD DE MURCIA

Facultad de Biología
UMU

# Análisis Multi-Ómico de la Enfermedad de Crohn

*Transcriptómica del Huésped y Metagenómica del Microbioma Intestinal*

**Laura Llamas López**
**María Sánchez Vivo**

Análisis de Datos Ómicos · Máster en Bioinformática · Curso 2025–2026 · Universidad de Murcia

# ÍNDICE

**1. Introducción** **2**

**2. Objetivos** **2**
2.1. Objetivo general . . . 2
2.2. Objetivos específicos . . . 2

**3. Materiales y métodos** **3**
3.1. Datos y selección de muestras . . . 3
3.1.1. Módulo A — Transcriptómica (RNA-seq) . . . 3
3.1.2. Módulo B — Metagenómica shotgun . . . 3
3.2. Análisis bioinformático en Galaxy . . . 4
3.2.1. Pasos comunes . . . 4
3.2.2. Módulo A — Pipeline de expresión diferencial . . . 5
3.2.3. Módulo B — Pipeline metagenómico . . . 5
3.3. Implementación en Nextflow . . . 5
3.4. Reproducibilidad y disponibilidad del código . . . 5

**4. Resultados y discusión** **6**
4.1. Módulo A — Expresión diferencial . . . 6
4.1.1. Expresión diferencial (DESeq2) . . . 6
4.1.2. Análisis funcional (DAVID) . . . 8
4.2. Módulo B — Metagenómica . . . 8
4.2.1. Composición taxonómica . . . 8
4.2.2. Diversidad alfa y beta . . . 10
4.2.3. Especies clave asociadas a la EC . . . 10
4.3. Discusión conjunta: integración transcriptómica-metagenómica . . . 11

**5. Conclusiones** **13**

**Referencias** **14**

**Material suplementario** **15**

# 1. INTRODUCCIÓN

La enfermedad de Crohn (EC) es una enfermedad inflamatoria intestinal (EII) crónica que afecta principalmente al íleon terminal y al colon, con un curso clínico caracterizado por períodos alternantes de remisión y recaída [1]. Su etiología es multifactorial: convergen factores genéticos —como las variantes de susceptibilidad en *NOD2*, *ATG16L1* y *NCF4* [2]—, alteraciones inmunológicas, disbiosis del microbioma intestinal y factores ambientales. La enfermedad puede generar complicaciones graves como estenosis, fístulas y abscesos, y afecta a más de 3 millones de personas en Europa y Norteamérica sin tratamiento curativo disponible [1].

La clasificación de Montreal codifica la localización anatómica de la EC en cuatro categorías: L1 (ileal), L2 (colónica), L3 (ileocólica) y L4 (tracto digestivo superior), clasificación relevante para la selección de muestras de este estudio. La actividad clínica se cuantifica mediante el Harvey-Bradshaw Index (HBI), un índice simplificado que evalúa bienestar general, dolor abdominal, número de deposiciones líquidas, masa abdominal y complicaciones extraintestinales; una puntuación <5 indica remisión, 5–7 actividad leve, 8–16 moderada y >16 grave [1].

Desde una perspectiva molecular, la EC implica la desregulación de la respuesta inmune innata y adaptativa en la mucosa intestinal, alteraciones en la barrera epitelial y cambios profundos en el microbioma. La disbiosis típica de la EC incluye la reducción de comensales productores de butirato (*Faecalibacterium prausnitzii*, *Roseburia* spp.) y el enriquecimiento de patobiontes como *Escherichia coli* adherente-invasiva [3, 4], aunque estas firmas no son universales [5].

Los avances en secuenciación de nueva generación (NGS) permiten abordar la EC desde perspectivas complementarias: la transcriptómica identifica genes y rutas biológicas alteradas en el huésped, mientras que la metagenómica *shotgun* caracteriza la composición taxonómica del microbioma. La integración multi-ómica de ambos niveles facilita una comprensión sistémica de la interacción huésped-microbioma [5, 6].

Este trabajo analiza datos públicos de RNA-seq de biopsias ileales y de metagenómica *shotgun* de muestras fecales para identificar, respectivamente, cambios en la expresión génica del huésped y alteraciones en la composición microbiana asociados a la EC, con el objetivo de integrar ambas perspectivas en una interpretación conjunta de los mecanismos patogénicos.

# 2. OBJETIVOS

## 2.1. Objetivo general

Caracterizar la respuesta molecular del huésped y la disbiosis microbiana asociadas a la EC mediante el análisis integrado de datos públicos de RNA-seq y metagenómica *shotgun*.

## 2.2. Objetivos específicos

**OE1. Módulo A — Transcriptómica.** Identificar genes diferencialmente expresados en biopsias ileales de pacientes con EC frente a controles sanos y evaluar su significado funcional por enriquecimiento (GO y KEGG).

**OE2. Módulo B — Metagenómica.** Caracterizar la composición taxonómica del microbioma fecal (EC vs. controles), evaluar la diversidad alfa y beta, e identificar taxa con abundancia diferencial respecto a firmas de disbiosis de la literatura.

**OE3. Integración.** Interpretar conjuntamente las alteraciones transcriptómicas del huésped y las del microbioma para proponer un modelo de interacción huésped-microbioma en la EC.

# 3. MATERIALES Y MÉTODOS

## 3.1. Datos y selección de muestras

Ambos módulos utilizan datos públicos en formato FASTQ de cohortes de EII que incluyen pacientes con EC y controles sanos. La plataforma de análisis principal fue Galaxy Europe (`https://usegalaxy.eu`). En cada módulo se seleccionó una subcohorte de 8 muestras (4 EC + 4 controles) para un análisis piloto manejable.

### 3.1.1. Módulo A — Transcriptómica (RNA-seq)

Se emplearon datos de RNA-seq del repositorio GEO (accesión GSE193677, BioProject PRJNA797175), procedentes de la cohorte MSCCR (Mount Sinai Crohn's and Colitis Registry) descrita por Argmann et al. [7]. El dataset completo comprende 2490 muestras (1157 EC, 872 colitis ulcerosa, 461 controles). Se seleccionaron 8 muestras: 4 de pacientes con EC y 4 controles sanos. Los criterios de selección fueron: homogeneidad tecnológica (Illumina HiSeq 2500, lecturas *single-end*), tejido exclusivamente ileal (íleon inflamado para EC, íleon no inflamado para controles) y profundidad de lectura comparable (30–50 millones de lecturas), verificada a partir de SraRunInfo.csv. Las muestras corresponden a los identificadores GEO: GSM5976576, GSM5976801, GSM5976985, GSM5977100, GSM5977177, GSM5977472, GSM5978421 y GSM5978855, resumidas en el Cuadro 1.

**Cuadro 1.** Muestras seleccionadas para el análisis transcriptómico.

| Accesión GEO | Diagnóst. | Sexo | Edad | Tejido |
|---|---|---|---|---|
| GSM5976576 | Control | Mujer | 55 | Íleon no inflamado |
| GSM5976985 | Control | Hombre | 50 | Íleon no inflamado |
| GSM5978421 | Control | Hombre | 42 | Íleon no inflamado |
| GSM5978855 | Control | Mujer | 51 | Íleon no inflamado |
| GSM5976801 | CD | Mujer | 34 | Íleon inflamado |
| GSM5977100 | CD | Hombre | 31 | Íleon inflamado |
| GSM5977177 | CD | Hombre | 35 | Íleon inflamado |
| GSM5977472 | CD | Mujer | 28 | Íleon inflamado |

CD: enfermedad de Crohn (biopsias de íleon inflamado).

### 3.1.2. Módulo B — Metagenómica shotgun

Las muestras proceden del repositorio NCBI SRA (BioProject PRJNA389280), correspondiente al Integrative Human Microbiome Project (IBDMDB) [5], que realizó un seguimiento longitudinal multiómico de 132 participantes (53 EC, 34 colitis ulcerosa, 45 controles sanos). Se utilizaron dos fuentes de metadatos —el RunInfo de NCBI SRA y los metadatos clínicos del repositorio IBDMDB (diagnóstico, edad, sexo, hospital, HBI)— cruzadas mediante el identificador de muestra común entre ambas fuentes.

Se seleccionaron 8 muestras de metagenómica *shotgun* para un estudio piloto comparativo EC vs. nonIBD (4 + 4), excluyendo los participantes con colitis ulcerosa para mantener una comparación binaria. La edad se restringió al rango 20–60 años para evitar la confusión con el microbioma pediátrico, cuya composición difiere estructuralmente del adulto, y con los cambios asociados al envejecimiento. Se exigió un tamaño mínimo de archivo de 500 MB por muestra para garantizar una profundidad de secuenciación suficiente para la clasificación taxonómica. Se impuso paridad de sexo (2 mujeres + 2 hombres por grupo) para minimizar el sesgo por esta variable de confusión conocida. Para las muestras EC se requirió actividad clínica documentada (HBI $\geq 5$) en la visita depositada en SRA, seleccionando la visita con el HBI más alto por participante para maximizar la

probabilidad de capturar señal de disbiosis; para las nonIBD se tomó la primera visita disponible (baseline). Las muestras seleccionadas se resumen en el Cuadro 2.

**Cuadro 2.** Muestras seleccionadas para el estudio piloto metagenómico.

| Participante | Diagnóst. | Sexo | Edad | HBI |
|---|---|---|---|---|
| M2025 | CD | Mujer | 43 | 6 |
| C3016 | CD | Mujer | 32 | 5 |
| C3017 | CD | Hombre | 45 | 5 |
| M2027 | CD | Hombre | 41 | 5 |
| M2077 | nonIBD | Mujer | 32 | — |
| M2039 | nonIBD | Mujer | 40 | — |
| M2079 | nonIBD | Hombre | 29 | — |
| M2042 | nonIBD | Hombre | 44 | — |

HBI: Harvey-Bradshaw Index ($\geq 5$ = actividad clínica). No aplica en controles nonIBD.

El diseño presenta limitaciones adicionales que deben reconocerse: la heterogeneidad de localización Montreal dentro del grupo EC (ileal L1 o ileocólica L3) puede incrementar la varianza intragrupo. Se evaluó restringir la selección a localización L1 para mejorar la comparabilidad con el Módulo A (biopsias ileales), pero de los cinco participantes EC con L1 en PRJNA389280 solo uno (M2027) presentaba HBI $\geq 5$, por lo que se priorizó la actividad clínica sobre la homogeneidad anatómica.

## 3.2. Análisis bioinformático en Galaxy

Todo el procesamiento bioinformático se ejecutó en Galaxy Europe. Los historiales públicos están disponibles en:

- Módulo A: `https://usegalaxy.eu/u/maria_sanchez_vivo/h/tarea`
- Módulo B: `https://usegalaxy.eu/u/lauullamas/h/metagenomica-mod-b`

### 3.2.1. Pasos comunes

Ambos módulos comparten las etapas iniciales del pipeline:

**Descarga de datos.** Las lecturas crudas en formato FASTQ se obtuvieron a partir de los identificadores SRA mediante la herramienta Faster Download and Extract Reads in FASTQ format from NCBI SRA. En el Módulo A se generaron ficheros FASTQ individuales (*single-end*); en el Módulo B, paired collections (R1/R2).

**Control de calidad.** Se evaluó con Falco (equivalente optimizado de FastQC), analizando calidad por posición, contenido de GC, presencia de adaptadores y secuencias sobre-representadas. En el Módulo B fue necesario aplanar la paired collection para que MultiQC generase un informe con las 16 entradas individuales.

**Filtrado y limpieza (fastp).** Se eliminaron adaptadores, bases de baja calidad y lecturas artefactuales. En el Módulo A el filtrado fue estándar, con una tasa de retención del 96,95 % y bases Q30 >95,8 %. En el Módulo B se configuraron parámetros específicos para metagenómica: eliminación del adaptador Nextera XT (`CTGTCTCTTATACACATCT`) con detección automática adicional, calidad mínima Q15, longitud mínima de 50 bp, filtro de baja complejidad (30 %) y corrección por solapamiento en *paired-end*; el análisis de duplicación se desactivó, ya que en metagenómica las lecturas idénticas pueden reflejar abundancia real. La contaminación por adaptadores fue notable (23–45 %), pero tras el filtrado la tasa de supervivencia osciló entre el 83 % y el 90 %, con lecturas de alta calidad libres de adaptadores.

#### 3.2.2. Módulo A — Pipeline de expresión diferencial

**Alineamiento (HISAT2).** Las lecturas filtradas (*single-end*) se alinearon contra el genoma de referencia humano GRCh38, con una tasa de mapeo promedio del 97,16 % (84,97 % alineamientos únicos, <4 % no mapeados).

**Cuantificación (featureCounts).** Se asignaron las lecturas a regiones génicas anotadas (hg38, tipo de característica exon, agrupación por gene_id, solo alineamientos primarios). En promedio, el 92 % de las lecturas alineadas se asignaron correctamente.

**Expresión diferencial (DESeq2).** Se definió el factor condition (EC vs. Control como referencia). Se aplicó normalización y modelado mediante distribución binomial negativa. Umbrales de significancia: p-adj $< 0{,}05$ y $|\log_2 \mathrm{FC}| > 1$. Se generaron PCA, MA-plot y Volcano plot.

**Análisis funcional (DAVID).** Los Entrez Gene IDs de los genes significativos se analizaron en DAVID Bioinformatics Resources (EASE Threshold = 0,1; Count Threshold = 2) para identificar términos GO y vías KEGG enriquecidos.

#### 3.2.3. Módulo B — Pipeline metagenómico

**Descontaminación del huésped (Bowtie2).** Las lecturas se alinearon contra el genoma humano completo (hg38, GRCh38) en modo `--very-sensitive`, conservando únicamente las lecturas no alineadas. La tasa de contaminación humana fue inferior al 1,46 % en todas las muestras.

**Clasificación taxonómica (Kraken2).** Se empleó la base de datos Standard-Full (2024-09-04) con un umbral de confianza de 0,1 para reducir falsos positivos.

**Estimación de abundancias (Bracken).** Se re-estimaron las abundancias a nivel de especie con un umbral mínimo de 10 lecturas, utilizando distribuciones precomputadas para lecturas de 100 bp.

### 3.3. Implementación en Nextflow

Se desarrollaron dos pipelines DSL2 en Nextflow que reproducen los análisis de ambos módulos, siguiendo las convenciones del ecosistema nf-core (módulos reutilizables, perfiles de ejecución diferenciados, patrón `tuple val(meta)/path(reads)`).

El pipeline del **Módulo A** sigue la secuencia:

$$\text{FASTQ} \rightarrow \text{fastp} \rightarrow \text{HISAT2} \rightarrow \text{featureCounts} \rightarrow \text{Falco} \rightarrow \text{DESeq2}$$

Para la validación del flujo de trabajo se emplearon datos de prueba reducidos (`dummy.fa`, `annotation.gtf`), dado que las muestras reales ocupan un espacio incompatible con la ejecución local.

El pipeline del **Módulo B** sigue la secuencia:

$$\text{FASTQ} \rightarrow \text{FALCO_RAW} \rightarrow \text{FASTP} \rightarrow \text{FALCO_TRIMMED} \rightarrow \text{BOWTIE2_ALIGN} \rightarrow \text{KRAKEN2} \rightarrow \text{BRACKEN} \rightarrow \text{MERGE_BRACKEN} + \text{MULTIQC}$$

Se utilizaron 6 módulos oficiales nf-core (falco, fastp, bowtie2/align, kraken2, bracken, multiqc) y un módulo local (`merge_bracken`) en Python/pandas para combinar los ficheros TSV de Bracken en una matriz especie × muestra. La configuración se centralizó en `nextflow.config` con tres perfiles: `dayhoff` (clúster SLURM de la Universidad de Murcia), `conda` (ejecución local) y `test` (validación stub-run). Ambos pipelines se validaron mediante stub-run, verificando la sintaxis DSL2, las conexiones entre canales y la propagación de metadatos.

### 3.4. Reproducibilidad y disponibilidad del código

Gran parte del análisis estadístico y la generación de figuras se realizaron en R. Todo el código fuente, las implementaciones en Nextflow y los archivos generados están disponibles en el repositorio de GitHub: `https://github.com/laullamas/analisis-multiomico-crohn`

# 4. RESULTADOS Y DISCUSIÓN

## 4.1. Módulo A — Expresión diferencial

### 4.1.1. Expresión diferencial (DESeq2)

DESeq2 identificó 7 genes diferencialmente expresados (p-adj $< 0{,}05$; $|\log_2 \mathrm{FC}| > 1$) entre pacientes con EC y controles sanos (Cuadro 3; Figura Suplementaria S1).

**Cuadro 3.** Genes diferencialmente expresados (DESeq2, p-adj $< 0{,}05$, $|\log_2 \mathrm{FC}| > 1$).

| Entrez ID | Símbolo | Nombre | $\log_2$ FC | p-adj |
|---|---|---|---|---|
| 53832 | IL20RA ↑ | Interleukin 20 receptor subunit alpha | +4,35 | 0,0019 |
| 4582 | MUC1 ↑ | Mucin 1, cell surface associated | +3,96 | 0,0471 |
| 729 | C6 ↓ | Complement C6 | −5,63 | 1,5e-05 |
| 57834 | CYP4F11 ↓ | Cytochrome P450 family 4 subfam. F member 11 | −4,00 | 0,0019 |
| 6492 | SIM1 ↓ | SIM bHLH transcription factor 1 | −7,37 | 0,0019 |
| 3024 | H1-1 ↓ | H1.1 linker histone, cluster member | −3,70 | 0,0429 |
| 4689 | NCF4 ↓ | Neutrophil cytosolic factor 4 | −1,61 | 0,0471 |

↑ sobreexpresado en EC; ↓ reprimido en EC.

Se identificaron 2 genes sobreexpresados en EC (*IL20RA* y *MUC1*) y 5 reprimidos (*C6*, *CYP4F11*, *SIM1*, *H1-1* y *NCF4*). Los cambios más drásticos correspondieron a *SIM1* ($\log_2 \mathrm{FC} = -7{,}37$) y *C6* ($\log_2 \mathrm{FC} = -5{,}63$, p-adj más significativo del conjunto). El Volcano plot (Figura 1) confirma visualmente la señal puntual: la gran mayoría de los genes se concentran en la base del gráfico, y solo estos 7 alcanzan significancia estadística, sugiriendo una respuesta transcriptómica limitada pero específica.

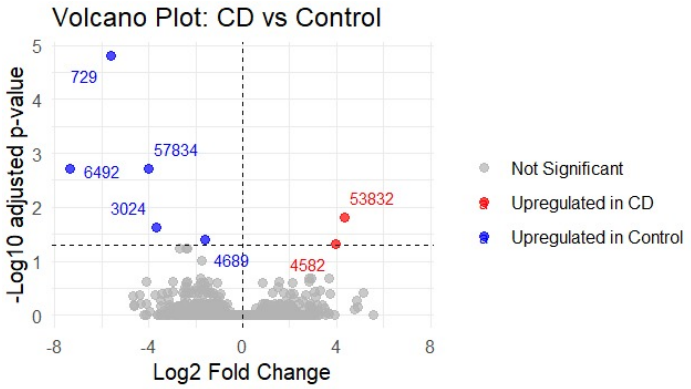


**Figura 1.** Volcano plot: EC vs. Control. El eje X representa el $\log_2$ fold change y el eje Y el $-\log_{10}$ p-adj. Los puntos rojos indican genes sobreexpresados en EC (*IL20RA*, *MUC1*) y los azules genes reprimidos en EC (*C6*, *CYP4F11*, *SIM1*, *H1-1*, *NCF4*). Líneas discontinuas: umbrales p-adj $= 0{,}05$ y $|\log_2 \mathrm{FC}| = 1$.

El PCA no segregó las condiciones clínicas (PC1 38 %, PC2 34 % de varianza): los grupos Control y EC no forman clústeres diferenciados ni compactos, observándose incluso outliers significativos y solapamiento entre ambas condiciones. El PC1 y el PC2 capturan proporciones similares de la variabilidad total, pero ninguno de ellos se alinea con el factor diagnóstico, lo que indica que la variabilidad técnica e interindividual domina sobre el efecto clínico (Figura 2). El MA-plot confirmó la adecuación de la normalización: la mayoría de los genes se distribuyen en torno a LFC $= 0$ sin tendencias sistemáticas, y los 7 DEGs se destacan en los extremos del eje de fold change (Figura 3). Se observa además la típica forma de *embudo*, donde la variabilidad del LFC aumenta en genes con bajos conteos normalizados, indicando que el ruido técnico limita la detección de diferencias en genes

poco expresados. Esta falta de separación en el PCA, coherente con el reducido tamaño muestral ($n = 4$ por grupo), no invalida los genes identificados pero limita la potencia para detectar cambios de menor magnitud.

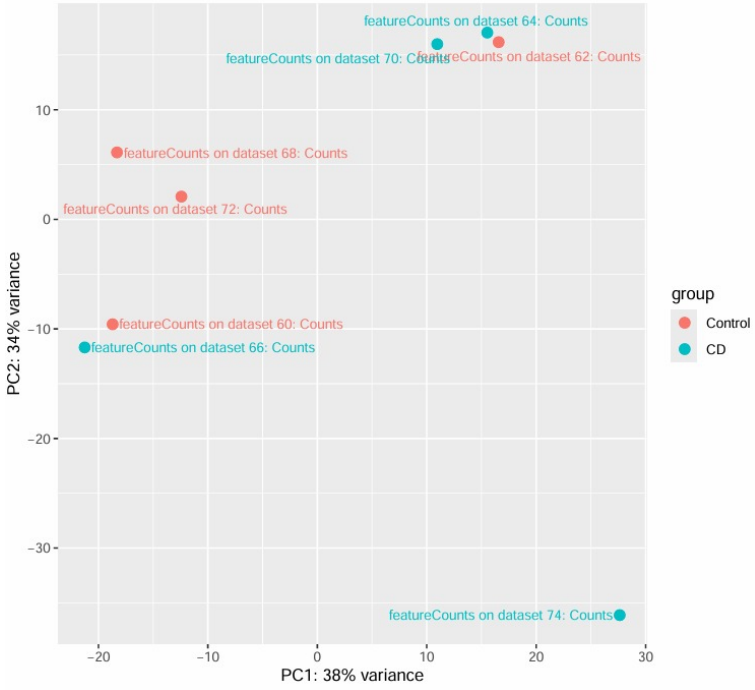


**Figura 2.** PCA de las 8 muestras de RNA-seq. Los puntos rojos representan controles y los azules pacientes con EC; PC1 (38 %) y PC2 (34 %) no segregan las condiciones clínicas.

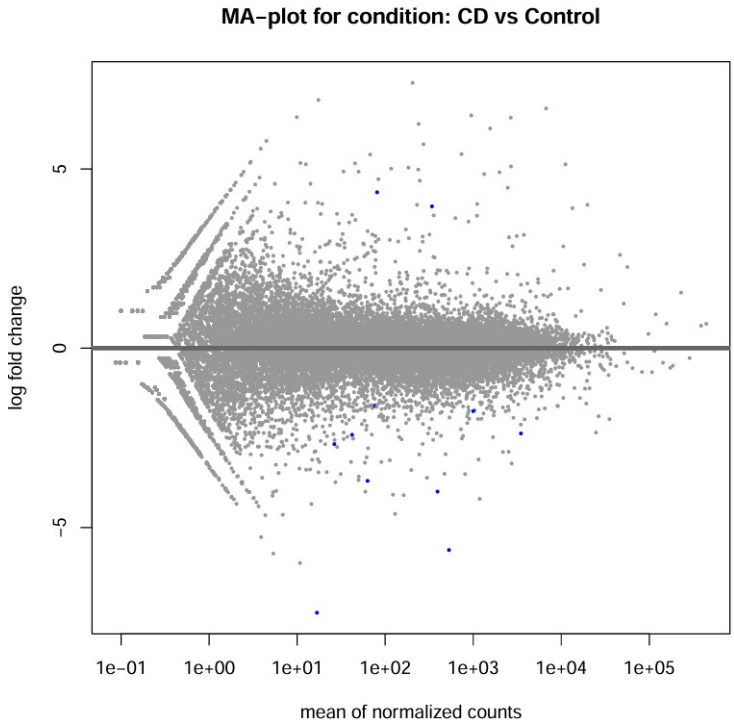


**Figura 3.** MA-plot EC vs. Control. La mayoría de los genes se distribuyen en torno a LFC = 0, confirmando la normalización; los 7 DEGs significativos se destacan en los extremos del eje de fold change.

Los 7 genes son biológicamente relevantes para la EC: *C6* participa en la cascada del complemento (inmunidad innata), *NCF4* es un componente del complejo NADPH-oxidasa esencial para la produc-

ción de ROS fagocíticos, *MUC1* e *IL20RA* regulan la barrera mucosa y la señalización inflamatoria, *CYP4F11* participa en el metabolismo de eicosanoides implicados en inflamación, y *H1-1* y *SIM1* reflejan posibles alteraciones en la regulación de la cromatina y la reprogramación transcripcional.

#### 4.1.2. Análisis funcional (DAVID)

El análisis de enriquecimiento funcional con DAVID identificó tres términos: chromatin (GO: CC_DIRECT, $p = 0{,}04$, 3 genes), vesicle (GO:CC_DIRECT, $p = 0{,}055$, 2 genes) y Prion disease (KEGG_PATHWAY, $p = 0{,}057$, 2 genes). El término chromatin fue el único que alcanzó significación nominal, sugiriendo posibles alteraciones en la regulación génica vinculadas a la activación sostenida de la inflamación crónica en la mucosa ileal. El término vesicle, aunque próximo al umbral, indicaría un posible papel del tráfico vesicular y la secreción de citocinas en la respuesta inmune intestinal. La vía Prion disease, aunque no directamente relacionada con la EC, podría reflejar mecanismos compartidos de estrés celular o mal plegamiento proteico. Ningún término mantuvo significación tras corrección por Benjamini-Hochberg (Benjamini $> 0{,}7$), por lo que estos hallazgos son exploratorios. El bajo número de genes de entrada (7) limita intrínsecamente la potencia del análisis de enriquecimiento, ya que las herramientas de enriquecimiento funcional están diseñadas para listas de genes más extensas (Figura Suplementaria S2).

### 4.2. Módulo B — Metagenómica

Bracken clasificó entre 7 y 21 millones de lecturas por muestra (Figura Suplementaria S3), identificando un total de 1775 especies. Pese a la heterogeneidad en profundidad, las curvas de rarefacción confirman que todas las muestras alcanzan la meseta de saturación (Figura Suplementaria S4), validando que la profundidad es suficiente para capturar la diversidad a nivel de especie. La riqueza asintótica osciló entre $\sim$350 y $\sim$1013 especies, con variabilidad notable entre individuos del mismo grupo. La rarefacción al mínimo del conjunto ($\sim$7,2 M lecturas) no alteró ningún valor de riqueza observada, por lo que las comparaciones de diversidad alfa se realizaron sobre los datos sin submuestreo. Tras eliminar lecturas residuales de *Homo sapiens* no capturadas por Bowtie2, la matriz final empleada en todos los análisis comprende las especies restantes.

#### 4.2.1. Composición taxonómica

Las 8 muestras están dominadas por Bacteroidota y Bacillota (antes Firmicutes), los dos filos principales del microbioma intestinal humano [8]. Las muestras nonIBD presentan mayor proporción de Bacteroidota, mientras que en las EC se observa mayor variabilidad en el ratio Bacteroidota/Bacillota [9] (Figura 4). Destaca M2039 (nonIBD) con una proporción elevada de Uroviricota ($\sim$10 %), correspondiente a bacteriófagos, un hallazgo puntual que probablemente refleja un episodio de inducción de profagos. La presencia residual de Pseudomonadota es consistente con su papel minoritario pero relevante en la disbiosis asociada a la EC.

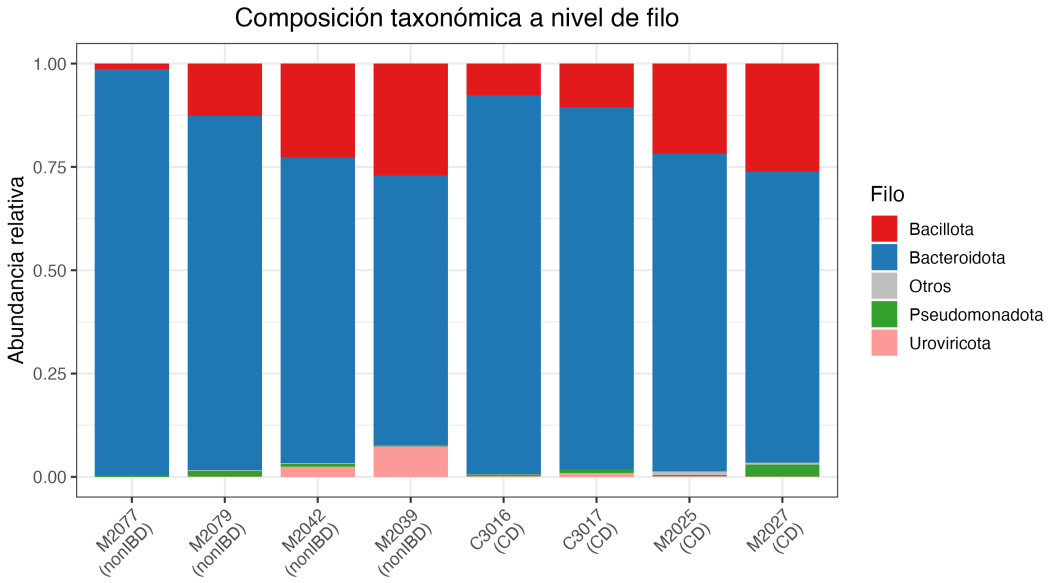


**Figura 4.** Composición taxonómica a nivel de filo por muestra. Abundancia relativa de los principales filos bacterianos en cada muestra, agrupadas por diagnóstico (nonIBD a la izquierda, CD a la derecha).

A nivel de género (Figura 5), la variabilidad interindividual es el rasgo más prominente. *Bacteroides* domina en la mayoría de muestras, alcanzando el 50–70 % en varias EC (C3016, C3017). El hallazgo más llamativo es la dominancia de *Segatella* (∼60 %) tanto en M2042 (nonIBD) como en M2027 (EC): esta especie, característica del enterotipo *Prevotella*, coexiste en un control sano y un paciente con EC, ilustrando que el enterotipo se mantiene independientemente del estado de enfermedad.

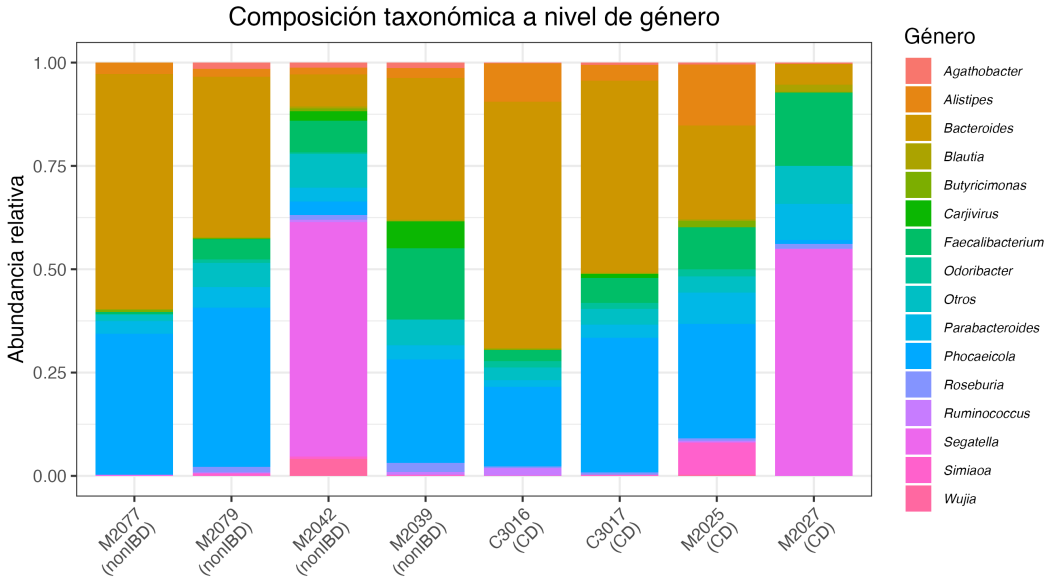


**Figura 5.** Composición taxonómica a nivel de género por muestra. Abundancia relativa de los 15 géneros más abundantes, agrupadas por diagnóstico (nonIBD a la izquierda, CD a la derecha).

La especie más abundante en ambos grupos fue *Phocaeicola vulgatus* (∼24 % nonIBD, ∼19 % EC), seguida de *Segatella copri*. Destaca *Bacteroides cellulosilyticus*, marcadamente más abundante en controles (∼9,5 %) que en EC (∼1 %). *F. prausnitzii* presentó abundancias similares entre grupos (∼4–5 %), sin la reducción esperable (Figura Suplementaria S5).

### 4.2.2. Diversidad alfa y beta

La diversidad alfa se evaluó mediante riqueza observada, índice de Shannon e índice de Simpson. La reducción de la diversidad alfa en la EII activa es un hallazgo recurrente en la literatura [10], pero en este estudio los valores muestran una elevada variabilidad dentro de cada grupo con rangos ampliamente solapados. M2077 (nonIBD) presenta 1013 especies frente a apenas 366 en C3017 (EC), pero M2025 (EC) muestra la mayor diversidad Shannon del conjunto (H' = 3,196), superando a todos los controles. El test de Wilcoxon no alcanzó significación en ninguna métrica ($p > 0{,}46$), resultado esperable con $n = 4$ y que no debe interpretarse como equivalencia biológica sino como limitación de potencia estadística (Figura Suplementaria S6).

El PCoA basado en Bray-Curtis (Figura 6) reveló que el primer eje (60,1 % de varianza) separa las muestras del enterotipo *Segatella* (M2027-EC y M2042-nonIBD) del resto, sin segregación diagnóstica: ambas, dominadas por el enterotipo *Segatella*, se desplazan hacia la derecha del espacio de ordenación, mientras que las muestras restantes se agrupan en el centro-izquierda con independencia del diagnóstico. Los centroides de ambos grupos son prácticamente coincidentes y las elipses al 68 % se solapan ampliamente. El PERMANOVA (Bray-Curtis $\sim$ diagnosis + sex, 999 permutaciones) confirma esta observación: $R^2 = 0{,}24$, $p = 0{,}699$, indicando que el 75,5 % de la varianza corresponde a variabilidad residual interindividual. La estructura del microbioma queda condicionada por el enterotipo antes que por el estado de enfermedad.

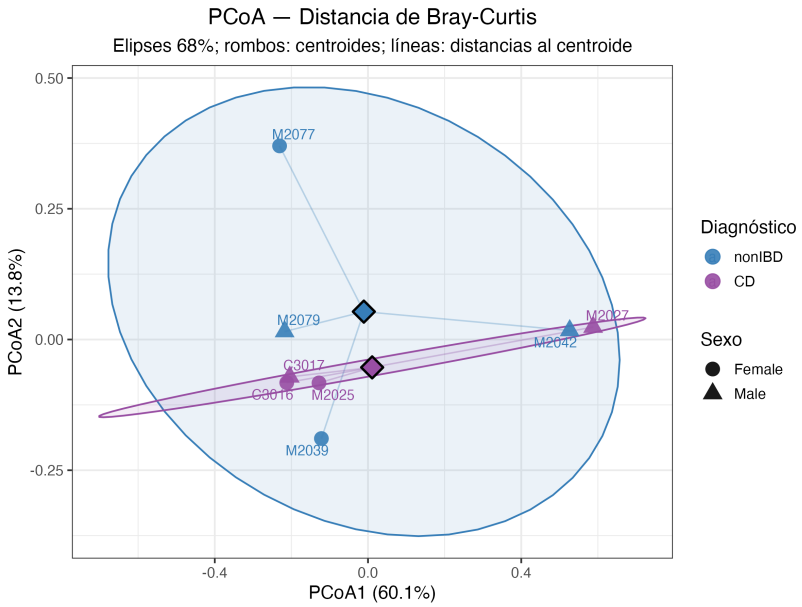


**Figura 6.** PCoA basado en distancias de Bray-Curtis. Las elipses al 68 % representan la dispersión de cada grupo diagnóstico; los rombos indican los centroides. El primer eje separa las muestras del enterotipo *Segatella* (M2027, M2042) del resto, con independencia del diagnóstico.

### 4.2.3. Especies clave asociadas a la EC

Se evaluó la abundancia de 14 especies identificadas por Lloyd-Price et al. [5] como marcadores de disbiosis en la EC, clasificadas según la dirección esperada: depleción en EC —productores de butirato como *F. prausnitzii*, *Roseburia* spp. y *Subdoligranulum*, además de la mucolítica *Akkermansia muciniphila*—, enriquecimiento en EC (*Escherichia coli*, *Ruminococcus gnavus*, *Veillonella parvula*) o comportamiento variable (*S. copri*, *P. vulgatus*). Se detectaron 12 de las 14; *Clostridium bolteae* y *Mediterraneibacter torques* quedaron por debajo del umbral mínimo de Bracken (10 lecturas).

De las 10 especies con dirección esperada definida, 5 reprodujeron el patrón descrito (Figura 7): *Agathobacter rectalis* y *Roseburia intestinalis* (productores de butirato) aparecen depletados en EC, mientras que *Escherichia coli* y *Veillonella parvula* están enriquecidos. *F. prausnitzii* no mostró la reducción esperada (FC = 1,14), resultado coherente con la naturaleza episódica de su depleción, que

se asocia preferentemente a episodios de mayor actividad inflamatoria [5], ausentes en muestras con HBI 5–6. El caso de *Akkermansia muciniphila* (FC = 201) refleja su presencia puntual en una única muestra EC frente a abundancias prácticamente nulas en los controles, lo que invalida el fold-change como estimador fiable para esta especie.

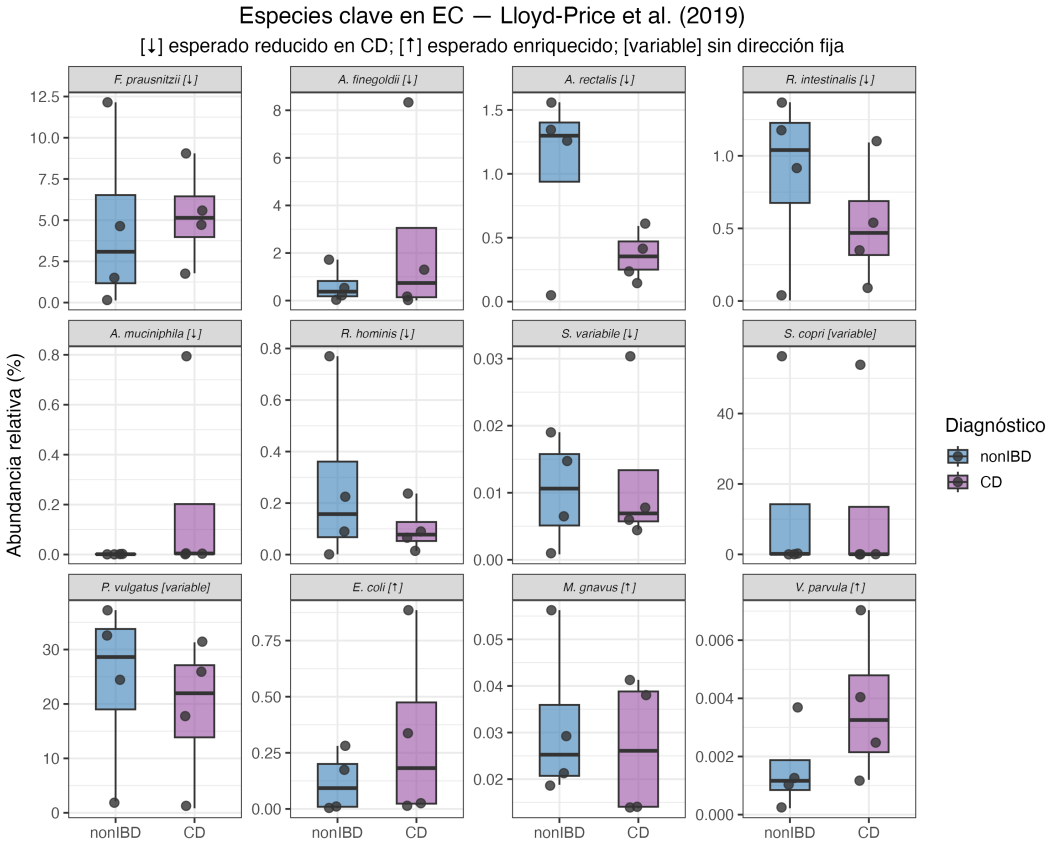


**Figura 7.** Abundancia relativa (%) de las especies clave en EC según Lloyd-Price et al. [5]. Los símbolos entre corchetes indican la dirección esperada: [↓] depletado en EC, [↑] enriquecido en EC, [variable] sin dirección fija. Cada punto representa una muestra individual.

El ratio Firmicutes/Bacteroidota fue inferior a 1 en todas las muestras, con medianas prácticamente idénticas entre grupos (nonIBD ∼0,23; EC ∼0,20), sin la alteración descrita en la literatura (Figura Suplementaria S7).

El heatmap de las 25 especies con mayor varianza (Figura Suplementaria S8) sintetiza la variabilidad composicional del conjunto: el clustering jerárquico de columnas no recupera separación por diagnóstico, con muestras EC y nonIBD entremezcladas. M2027 (EC) queda aislada por su perfil dominado por *Segatella copri* y *Parabacteroides distasonis*, y se agrupa con M2042 (nonIBD), que comparte el enterotipo *Prevotella*. M2042 (nonIBD) y M2025 (EC) se agrupan entre sí pese a diagnósticos opuestos. Las formas de *Faecalibacterium* detectadas no muestran patrón diagnóstico. El resultado confirma que el enterotipo estructura la variabilidad composicional de forma más determinante que el diagnóstico.

### 4.3. Discusión conjunta: integración transcriptómica-metagenómica

**Convergencia en la debilidad de la señal diferencial.** Ambos módulos coinciden en la dificultad de separar los grupos EC y control: el PCA transcriptómico no segrega las condiciones clínicas y solo identifica 7 DEGs; en la metagenómica, la diversidad alfa y beta no difieren significativamente y el clustering no recupera separación por diagnóstico. Esta convergencia es esperable dadas las limitaciones compartidas — tamaño muestral reducido, actividad clínica moderada y variabilidad interindividual que eclipsa la señal de grupo en ambos niveles ómicos [5].

**Barrera mucosa: MUC1 y la interfaz huésped-microbioma.** La sobreexpresión de *MUC1* en biopsias ileales de EC puede interpretarse como una respuesta compensatoria del epitelio ante la inflamación crónica y la alteración de la capa de moco. *MUC1* codifica una glicoproteína transmembrana de la superficie apical del epitelio intestinal cuya función primaria es la protección contra la invasión microbiana. Desde la perspectiva metagenómica, la depleción de *B. cellulosilyticus* en EC (∼9,5 % en controles vs. ∼1 % en EC) resulta coherente: esta especie sacarolítica que degrada polisacáridos vegetales depende de un nicho mucoso intacto, y su reducción podría reflejar tanto la alteración de la composición del moco como el ambiente inflamatorio local [11]. De manera complementaria, el elevado FC de *Akkermansia muciniphila* (FC = 201) —especie mucolítica con mayor prevalencia en la mucosa de pacientes con EII respecto a controles sanos [11]— no contradice la literatura, sino que es coherente con la alteración del moco inducida por *MUC1*, que podría favorecer la colonización de bacterias mucolíticas.

**Inmunidad innata, NCF4 y patobiontes.** La represión de *NCF4*, componente del complejo NADPH-oxidasa de los fagocitos esencial para la producción de especies reactivas de oxígeno (ROS) y la autofagia de bacterias intracelulares, es particularmente relevante para la interacción huésped-microbioma. Variantes en *NCF4* se han asociado genéticamente a susceptibilidad a la EC [2], y un déficit funcional implicaría una menor capacidad de eliminación de patobiontes. Este hallazgo es coherente con el enriquecimiento de *E. coli* observado en las muestras EC del Módulo B: *E. coli* adherente-invasiva (AIEC) coloniza la mucosa ileal de pacientes con EC y es habitualmente controlada por mecanismos fagocíticos dependientes de ROS [12]. La represión simultánea de *C6* (componente C6 del complemento) refuerza esta hipótesis de déficit en la inmunidad antimicrobiana innata, dado que la vía del complemento contribuye a la opsonización y lisis de bacterias gram-negativas como *E. coli*.

**Inflamación por citocinas y disbiosis.** La sobreexpresión de *IL20RA* conecta la señalización de citocinas proinflamatorias con la disbiosis: IL-20 está implicada en la activación inmune en la mucosa intestinal [13], y su señalización exacerbada podría favorecer el enriquecimiento de bacterias tolerantes al estrés oxidativo (*V. parvula*) y la reducción de productores de butirato (*A. rectalis*, *R. intestinalis*). El butirato, principal fuente de energía de los colonocitos con propiedades antiinflamatorias [14], actuaría además como modulador epigenético al inhibir histona-desacetilasas [15], lo que conecta su depleción con las alteraciones en la cromatina detectadas en el transcriptoma (*H1-1*↓, *SIM1*↓; enriquecimiento del término chromatin en DAVID, $p = 0{,}04$).

**Modelo integrador.** Pese a estas limitaciones, los resultados revelan un modelo coherente: la EC se manifiesta en la interfaz huésped-microbioma como la coexistencia de disfunción inmune innata (*NCF4*↓, *C6*↓), activación inflamatoria (*IL20RA*↑) y respuesta compensatoria de la barrera mucosa (*MUC1*↑) en el huésped, junto con el enriquecimiento de patobiontes (*E. coli*, *V. parvula*) y la depleción de comensales protectores (*A. rectalis*, *R. intestinalis*) en el microbioma, con la pérdida de butirato como posible nexo entre la disbiosis y la reprogramación epigenética del epitelio.

**Limitaciones.** Los resultados de este trabajo deben interpretarse a la luz de varias limitaciones de diseño. La más inmediata es el tamaño muestral: con $n = 4$ por grupo en ambos módulos, la potencia estadística es insuficiente para detectar diferencias de efecto moderado tras corrección por pruebas múltiples, por lo que todos los hallazgos tienen carácter exploratorio. A esto se suma que las muestras de EC del Módulo B corresponden a una actividad clínica moderada (HBI 5–6), muy por debajo de los episodios de mayor inflamación documentados en la cohorte IBDMDB completa (HBI $> 16$), donde las alteraciones del microbioma son más pronunciadas y reproducibles [5]; el reducido número de muestras que reunían simultáneamente HBI suficiente y criterios de calidad técnica obligó a aceptar esta franja de actividad. En este contexto, la variabilidad interindividual eclipsa la señal diagnóstica, como es esperable cuando factores estables como la dieta o el entorno determinan la estructura del microbioma de forma más intensa que la propia patología.

A nivel de diseño multi-ómico, la integración entre módulos presenta limitaciones inherentes: los datos de transcriptómica (PRJNA797175, cohorte MSCCR) y metagenómica (PRJNA389280, cohorte IBDMDB) proceden de cohortes independientes, con pacientes, centros y diseños de estudio distintos,

de modo que las asociaciones entre hallazgos son necesariamente indirectas, sin derivar de mediciones pareadas en los mismos individuos. Además, los compartimentos biológicos analizados difieren: las biopsias de mucosa ileal del Módulo A no son equivalentes a las heces del Módulo B. Por último, dentro del grupo EC del Módulo B coexisten localizaciones anatómicas L1 (ileal) y L3 (ileocólica), lo que incrementa la varianza intragrupo, y las muestras EC proceden de dos centros hospitalarios distintos (Cedars-Sinai y MGH) frente a la procedencia única (MGH) de los controles, introduciendo un potencial sesgo de sitio clínico.

Pese a todo ello, el estudio demuestra la viabilidad del enfoque multi-ómico integrador sobre datos públicos y genera hipótesis concretas que podrían contrastarse en cohortes mayores con datos pareados y muestras recogidas durante episodios de mayor actividad inflamatoria.

## 5. CONCLUSIONES

1. **Expresión diferencial del huésped.** Se identificaron 7 genes diferencialmente expresados en biopsias ileales de pacientes con EC (p-adj $< 0{,}05$; $|\log_2 \mathrm{FC}| > 1$). La sobreexpresión de *MUC1* e *IL20RA* apunta a la activación de la barrera mucosa y la señalización inflamatoria; la represión de *NCF4*, *C6*, *CYP4F11*, *H1-1* y *SIM1* sugiere déficits en la inmunidad innata y alteraciones epigenéticas.

2. **Composición del microbioma fecal.** La caracterización taxonómica reveló perfiles dominados por Bacteroidota y Bacillota, con depleción de productores de butirato (*A. rectalis*, *R. intestinalis*) y enriquecimiento de patobiontes (*E. coli*, *V. parvula*) en EC, reproduciendo parcialmente (5/10 taxa) las firmas de disbiosis descritas por Lloyd-Price et al. [5].

3. **Ausencia de diferencias estadísticamente significativas.** Ni la diversidad alfa/beta ni el PCA transcriptómico separaron los grupos, resultado atribuible al tamaño muestral reducido, la actividad clínica moderada (HBI 5–6) y la heterogeneidad interindividual.

4. **Integración multi-ómica.** La discusión conjunta reveló un modelo coherente: la disfunción de la inmunidad innata (*NCF4*↓, *C6*↓) se asocia al enriquecimiento de *E. coli*; la activación inflamatoria (*IL20RA*↑) coexiste con la pérdida de productores de butirato; y la respuesta compensatoria de la barrera mucosa (*MUC1*↑) se relaciona con la depleción de *B. cellulosilyticus*. La pérdida de butirato podría retroalimentar las alteraciones epigenéticas del epitelio (*H1-1*↓, *SIM1*↓).

5. **Implementación computacional.** Ambos módulos se implementaron como pipelines Nextflow DSL2, validados mediante stub-run, garantizando reproducibilidad y escalabilidad.

## REFERENCIAS


[1] Torres J, Mehandru S, Colombel JF, Peyrin-Biroulet L. Crohn's disease. *Lancet.* 2017;389(10080):1741–55.

[2] Jostins L, Ripke S, Weersma RK, et al. Host-microbe interactions have shaped the genetic architecture of inflammatory bowel disease. *Nature.* 2012;491:119–24.

[3] Frank DN, St. Amand AL, Feldman RA, et al. Molecular-phylogenetic characterization of microbial community imbalances in human inflammatory bowel diseases. *Proc Natl Acad Sci USA.* 2007;104(34):13780–5.

[4] Sokol H, Pigneur B, Watterlot L, et al. *Faecalibacterium prausnitzii* is an anti-inflammatory commensal bacterium identified by gut microbiota analysis of Crohn disease patients. *Proc Natl Acad Sci USA.* 2008;105(43):16731–6.

[5] Lloyd-Price J, Arze C, Ananthakrishnan AN, et al. Multi-omics of the gut microbial ecosystem in inflammatory bowel diseases. *Nature.* 2019;569:655–62.

[6] Hasin Y, Seldin M, Lusis A. Multi-omics approaches to disease. *Genome Biol.* 2017;18:83.

[7] Argmann C, Hou R, Ungaro RC, et al. Biopsy and blood-based molecular biomarker of inflammation in IBD. *Gut.* 2023;72(7):1271–87.

[8] Human Microbiome Project Consortium. Structure, function and diversity of the healthy human microbiome. *Nature.* 2012;486:207–14.

[9] Magne F, Gotteland M, Gauthier L, et al. The Firmicutes/Bacteroidetes ratio: A relevant marker of gut dysbiosis in obese patients? *Nutrients.* 2020;12(5):1474.

[10] Manichanh C, Rigottier-Gros L, Bonnaud E, et al. Reduced diversity of faecal microbiota in Crohn's disease revealed by a metagenomic approach. *Gut.* 2006;55(2):205–11.

[11] Png CW, Lindén SK, Gilshenan KS, et al. Mucolytic bacteria with increased prevalence in IBD mucosa augment in vitro utilization of mucin by other bacteria. *Am J Gastroenterol.* 2010;105(11):2420–8.

[12] Darfeuille-Michaud A, Boudeau J, Bulois P, et al. High prevalence of adherent-invasive *Escherichia coli* associated with ileal mucosa in Crohn's disease. *Gastroenterology.* 2004;127(2):412–21.

[13] Dumoutier L, Leemans C, Lejeune D, et al. Cutting edge: STAT activation by IL-19, IL-20 and mda-7 through IL-20 receptor complexes of two types. *J Immunol.* 2001;167(7):3545–9.

[14] Hamer HM, Jonkers D, Venema K, et al. The role of butyrate on colonic function. *Aliment Pharmacol Ther.* 2008;27(2):104–19.

[15] Davie JR. Inhibition of histone deacetylase activity by butyrate. *J Nutr.* 2003;133(7 Suppl):2485S–93S.

# MATERIAL SUPLEMENTARIO

| GeneID | Base mean | log2(FC) | StdErr | Wald-Stats | P-value | P-adj |
|---|---|---|---|---|---|---|
| 729 | 530.695466453873 | -5.62645313551657 | 0.915987869821701 | -6.14249742915458 | 8.12339930061129e-10 | 1.54661399284338e-05 |
| 57834 | 392.915499340605 | -3.99732904038554 | 0.780523095954011 | -5.12134626266212 | 3.03362008711164e-07 | 0.00192523642795062 |
| 6492 | 16.7732480956547 | -7.37317727115639 | 1.4301728494736 | -5.15544486379406 | 2.53029488226784e-07 | 0.00192523642795062 |
| 53832 | 80.8967205262599 | 4.34791249194967 | 0.934025975085915 | 4.65502310206067 | 3.23944382659148e-06 | 0.0154189427536188 |
| 3024 | 63.0134814177105 | -3.69733325396551 | 0.818548767215719 | -4.5169370501185 | 6.27405468601513e-06 | 0.0238903454334084 |
| 4689 | 76.6959974042639 | -1.61437250989779 | 0.369719957173865 | -4.36647380963159 | 1.26268420297749e-05 | 0.0400670742341475 |
| 4582 | 340.070878814423 | 3.95647516401328 | 0.920773789483379 | 4.29690246312631 | 1.73201358847667e-05 | 0.047108295301439 |

**Figura Suplementaria S1.** Tabla de resultados de DESeq2 para los 7 genes significativos: base mean, $\log_2$FC, StdErr, Wald-Stats, p-value y p-adj (Módulo A).

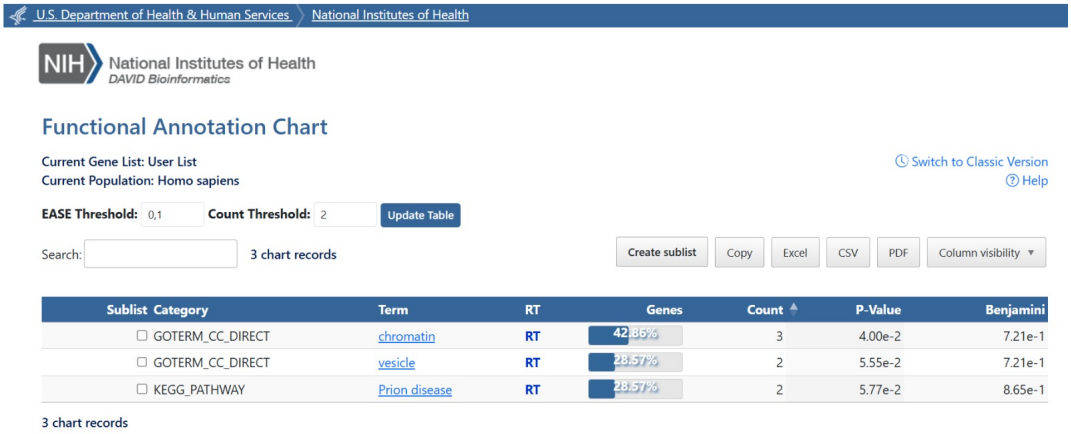


**Figura Suplementaria S2.** Resultados del análisis de enriquecimiento funcional (DAVID). Se muestran los tres términos identificados: chromatin ($p = 0{,}04$), vesicle ($p = 0{,}055$) y Prion disease ($p = 0{,}057$). Ninguno mantuvo significación tras corrección de Benjamini-Hochberg (Módulo A).

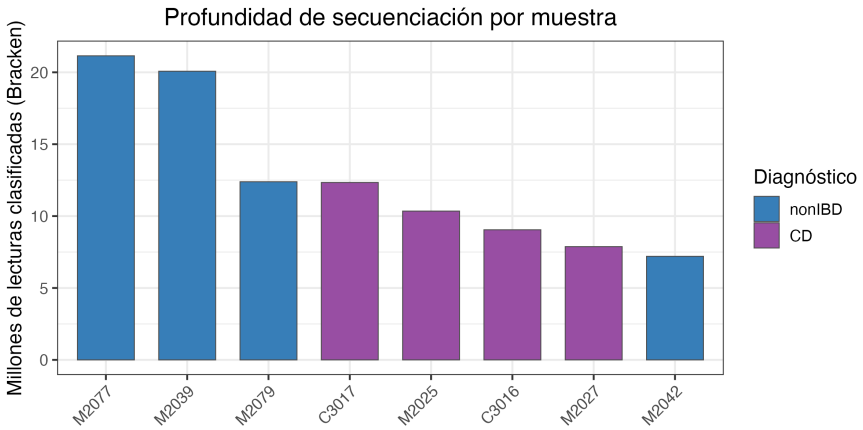


**Figura Suplementaria S3.** Profundidad de secuenciación por muestra. Número de lecturas clasificadas por Bracken (en millones), coloreadas por diagnóstico (Módulo B).

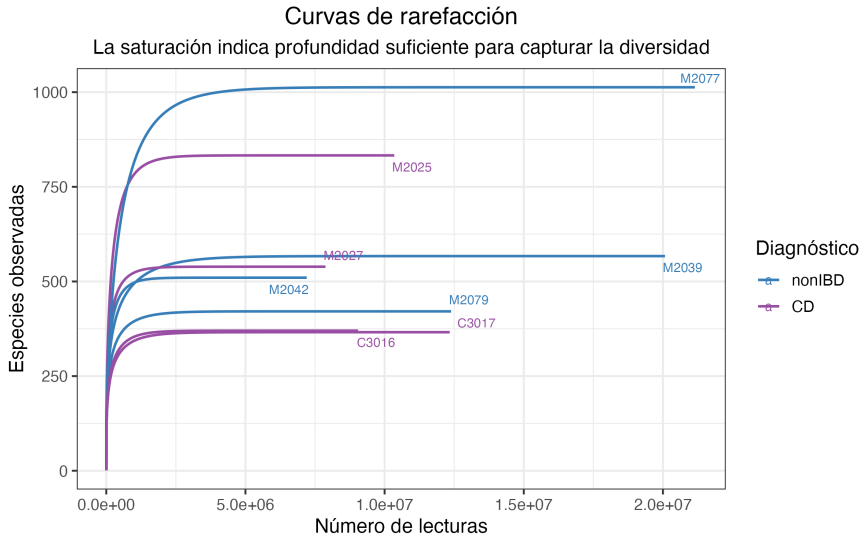


**Figura Suplementaria S4.** Curvas de rarefacción. Todas las muestras alcanzan la meseta de saturación, confirmando que la profundidad de secuenciación es suficiente (Módulo B).

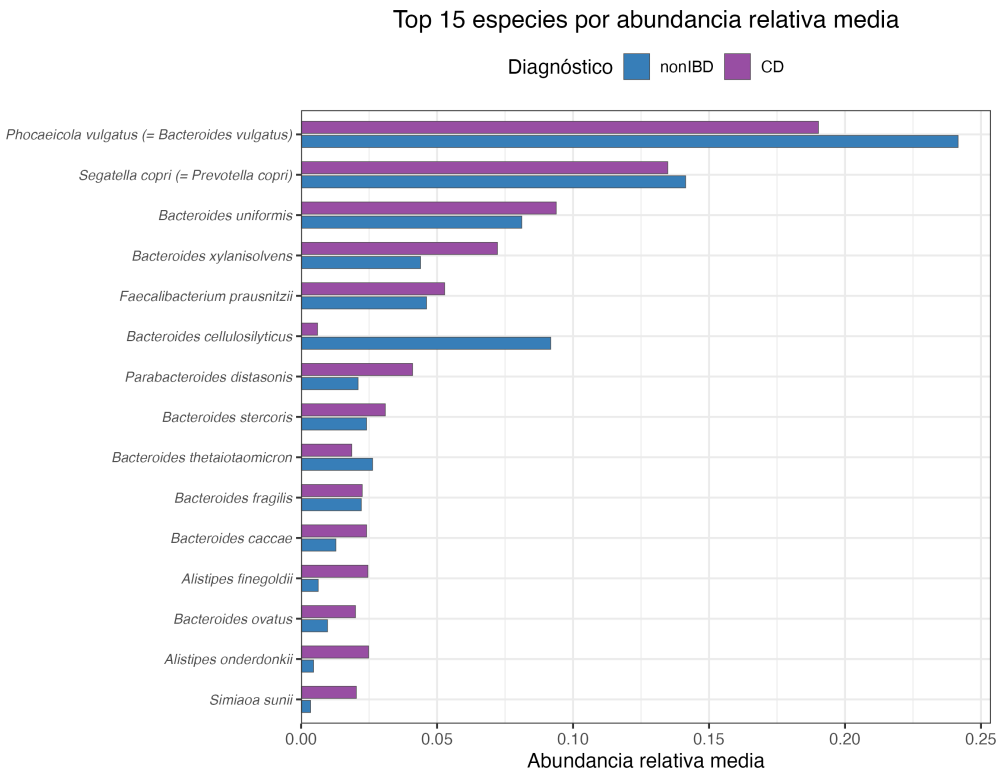


**Figura Suplementaria S5.** Top 15 especies por abundancia relativa media, agrupadas por diagnóstico (Módulo B).

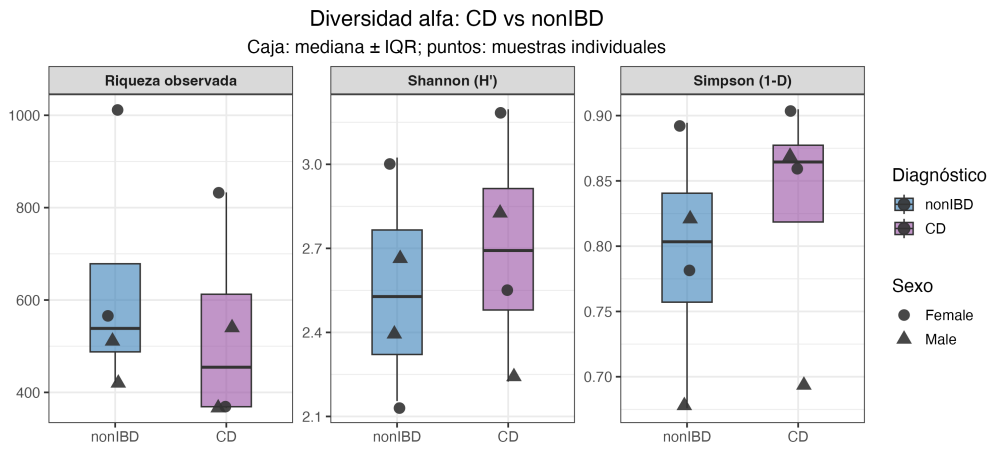


**Figura Suplementaria S6.** Diversidad alfa: EC vs. nonIBD. Boxplots de riqueza observada, Shannon H' y Simpson 1-D (Módulo B).

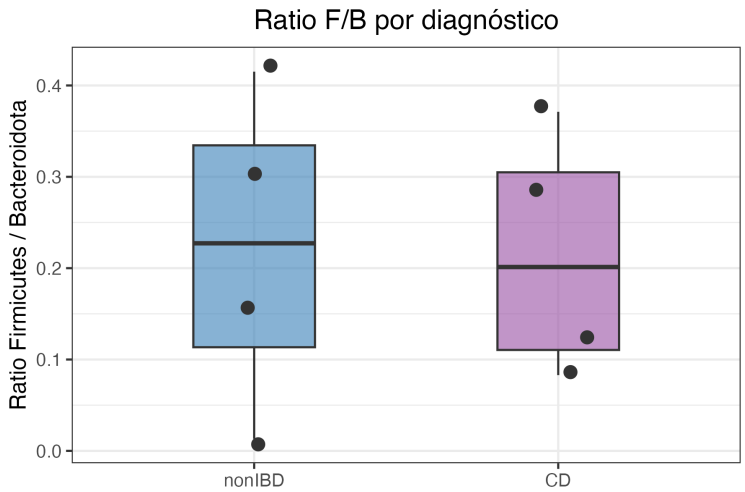


**Figura Suplementaria S7.** Ratio Firmicutes/Bacteroidota por grupo diagnóstico (Módulo B).

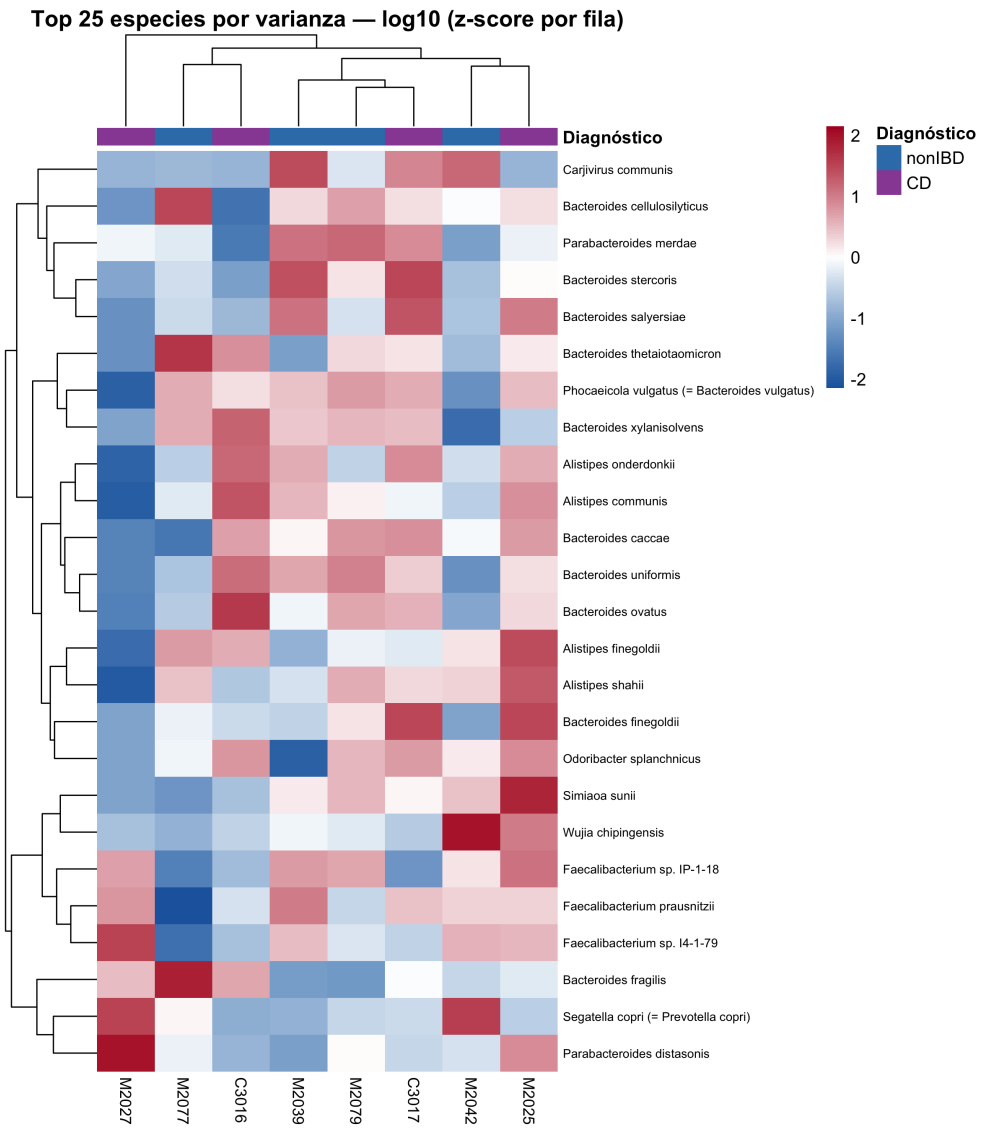


**Figura Suplementaria S8.** Heatmap de las 25 especies con mayor varianza entre muestras. Valores en $\log_{10}$ de abundancia relativa estandarizados por fila (z-score). El clustering jerárquico no recupera separación por diagnóstico (Módulo B).